

삼성화재XPOSTECH

제2회 데이터기반 리스크관리 경진대회

기업 리스크 관리를 위한 유튜버 등급 평가모형 및 예측모델 개발

팀명 : 정규함수



목차

서론

- 인플루언서 마케팅 시장 규모 및 현황
- 유튜브 산업의 성장
- 유튜브 산업의 성장에 따른 이머징 리스크
- 분석과정

본론

- 데이터 설명
 - 분석 대상 설정
 - 데이터 수집
 - 데이터 전처리
- 데이터 분석
 - 감성분석 모델
 - 유튜버별 월 등급 산정
 - 머신러닝 및 딥러닝 기법을 활용한 분석
- 데이터 분석 결과
 - 유튜버 등급 시계열적 분석

결론

- 유튜버 평판 리스크 보험
- 페르소나 설정
- 한계 및 연구 방향

부록 및 참고 문헌

- 부록 A. 머신러닝 및 딥러닝 방법론
- 참고 문헌

SUMMARY

최근 유튜버 산업 및 소셜 미디어를 이용한 광고의 성장으로 이머징 리스크가 발생하고 있다. 이에 본 프로젝트에서는 유튜버를 활용한 광고에서 발생할 수 있는 여러 유형의 리스크를 분석하고 관리하는 체계를 고안하였다. 이러한 체계로 광고를 진행하는 기업에게는 안전성을, 성장을 거듭하고 있는 산업에게는 안정성을 부여해줄 수 있을 것으로 예상된다.

서론


1.1 인플루언서 마케팅 시장 규모 및 현황

TV 광고나 신문 전면광고를 통해 무차별적으로 제품을 홍보하던 시절은 지나가고 개개인의 욕구에 딱 맞는 맞춤형 광고가 가능한 시대가 왔다. 현재 인플루언서가 온라인 광고 분야의 왕좌에 올랐다는 데에는 의심의 여지가 없다. 2018년 나스미디어가 발표한 마케팅 트렌드 보고서에 따르면, 2020년 국내 인플루언서 마케팅 시장은 약 2조 100억 원의 규모로 예상되어졌고 글로벌 인플루언서 시장은 올해 약 7조 원을 내다보고 있다. 글로벌 리서치 회사 '마켓츠앤마켓츠'는 2021년 약 7조 규모의 인플루언서 마케팅 시장이 연간 32%의 성장률을 지속하여, 2025년에는 약 28조 원의 규모로 커질 것으로 예상하고 있다.

인플루언서는 현시대 가장 강력한 마케팅 채널이자 광고 소재가 되었다. 디지털 광고 시장의 지속된 성장과 더불어 코로나19로 인한 브랜드 온라인 채널 집중 강화 전략의 수혜도 입었다. 기존 TV 광고 및 연예인 모델의 엄청난 제작비와 계약료를 고려한다면, 인플루언서 마케팅은 여전히 비용 대비 큰 잠재력을 가진 매력적인 전략이다. 인플루언서 마케팅에 대한 브랜드 여론도 긍정적이다. 최근 통계에 따르면 약 90%의 브랜드가 인플루언서 마케팅이 효과적이라고 생각하며, 인플루언서가 소셜 미디어 네트워크에서 훨씬 더 많은 타겟에 도달할 수 있다고 판단한다.

*인플루언서 마케팅 : 소셜 미디어에서 영향력을 행사하는 인플루언서들의 입을 빌려 브랜드나 상품을 소비자에게 소개하고 공유하는 새로운 마케팅 방식

인플루언서마케팅 시장 규모 및 현황



1.2 유튜브 산업의 성장

인플루언서가 활동하는 대표적인 플랫폼인 유튜브는 2006년 구글 인수 후 본격적인 서비스를 시작하면서 세계적인 동영상 플랫폼으로 성장 중이다. 유튜브의 월 사용자 수는 19억 명에 달하며 전 세계인이 매일 유튜브에서 10억 시간 분량의 동영상을 시청하고 있다. 국내의 경우, 유튜브 이용자의 72.1%가 평소 유튜브를 자주 이용하고, 42.8%가 하루 평균 1시간 이상의 유튜브를 사용하는 것으로 나타났다.

2022년 모바일 인덱스 분석 결과, 유튜브 앱 월간 활성 사용자 수가 4183만명으로 대한민국 인구의 약 81%가 사용하는 것으로 나타났다. 사용시간으로 환산해 보았을 때 13억 8057만 3,200시간으로 1인당 월평균 32.9시간 유튜브를 사용한 것이다. 또한 유튜브는 한국인이 사용하는 주요 앱 중 가장 이탈률이 낮은 앱인 반면 사용률은 98.7%로 주요 매체 중 가장 높았다.

2022년 한국 유튜브 누적 구독자 수는 46억을 기록, 누적 조회수 또한 1조 924억을 기록하여 바로 전년도인 2021년도와 대비하여 26.5% 성장했음을 알 수 있다.

이를 통해 현재 전 국민이 유튜브를 사용한다고 봐도 과언이 아니며, 이러한 유튜브의 점유율은 계속해서 상승할 것으로 보인다.

이러한 유튜브의 성장과 함께 기업의 브랜드 또는 제품 마케팅에 소셜 미디어를 활용하기 위하여 노력하고 있으며, 유튜브를 활용한 인플루언서 마케팅에 대한 관심이 증가하고 있다. 과거에는 관련이 없더라도 유명세의 연예인을 통해 광고하였다면 현재는 제품과 관련된 유튜버들을 통해서 더 신뢰감 있는 광고를 제공할 수 있다는 기대를 제고한다.

1.3 유튜브 산업의 성장에 따른 이머징리스크

유튜버 산업은 급속한 성장을 거듭하며, 이에 따른 새로운 리스크 요인들이 두드러지게 나타나고 있다. 특히, 인플루언서 마케팅을 활용하는 기업들은 인플루언서의 부적절한 언행으로 인해 배상책임 및 저작권 침해와 같은 다양한 위험에 노출될 가능성이 커지고 있다. 동시에 인플루언서 자체도 전문성 부족 등으로 인한 손해배상 문제에 직면할 수 있다. 다양한 종류의 리스크가 존재하는 상황에서, 본 프로젝트는 <기업이 유튜버에게 광고를 제공함으로써 발생할 수 있는 리스크>를 중점적으로 분석하고자 한다. 이머징 리스크 특성으로 인해 실례를 쉽게 찾아보기 어려운 상황에서 유명 연예인이 광고 모델로 활동할 때 발생하는 사례를 중심으로 기업과 인플루언서 간의 관계에서 발생할 수 있는 다양한 리스크를 탐구하고자 한다.

(1) 유튜버와 기업의 협업 범위 확대에 따른 리스크

광고 업계에서 유튜버들이 크게 주목받고 있다. 비슷한 비용으로 일반적인 연예인은 소속사를 통해 활동하며 TV, 신문 등을 통해 제한적인 노출로 인해 비용 효율이 낮지만 유튜버들은 개인 사업자로 활동하며 본인의 채널 및 오프라인과 SNS를 통한 마케팅을 효율적으로 진행할 수 있어 비교적 비용 효율이 높다.

최근 유튜버와 기업 간의 협업이 단순한 제품 협찬이나 광고를 넘어 제품 개발까지 그 범위가 확대되고 있다. 특히 온라인 뷰티 콘텐츠의 경우, 제품에 관한 영상 시청이 실구매로 이어지는 구매 전환율이 높다고 알려져 있어 기업과 유튜버 간의 협업이 늘어나는 추세다. 그러나, 유튜버가 협업한 제품은 해당 유튜버의 이미지와 직결되므로 리스크를 내포하고 있다고 할 수 있다. 연예인의 경우, 세븐일레븐의 '임창정의 소주 한 잔'과 같은 사례에서 볼 수 있다. 이 제품은 출시 직후 몇 시간 만에 완판되며 세븐일레븐의 증류주 매출 1위를 차지하는 등 큰 인기를 끌었다. 그러나 임창정과 주가 조작 의혹에 관한 의심이 불거지면서 '소주 한 잔'은 시장에서 퇴출당하였다. 이처럼, 기업과 유튜버 간의 협업을 통해 출시된 제품의 경우에도 유튜버의 이미지와 직접적으로 연결되어 있어 리스크가 발생할 수 있다.

(2) 유튜브 광고계약 특성으로 발생하는 리스크

일반적으로 광고주가 모델이나 유명 연예인, 운동선수 등과 광고모델 계약을 체결하는 경우 연예인에게 일정한 수준의 명예를 유지할 의무를 부과하는, 일명 '품위유지의무' 조항이 포함된다. 품위유지의무 조항은 광고모델이 계약 기간 중 자기 행동으로 인해 사회적, 도덕적 명예를 훼손하지 않도록 하는 목적을 가지고 있다. 그러나 일정 기간 지속해서 기업의 제품을 홍보하는 일반적인 광고모델과는 달리, 유튜버의 콘텐츠 출연은 일회성에 그치는 경우가 대다수이고 광고 모델 계약이 아닌 다른 형태의 계약으로 체결하는 경우도 많다. 그에 따라 광고모델 계약에 당연히 포함되는 품위유지의무 조항을 간과하는 경우가 생기기 마련이다. 또한 유튜브 광고 계약 사항이 자세하지 않은 경우, 위약금조차 포기할 수밖에 없는 문제가 발생한다.

(3) 광고 모델의 사회적 물의의 모호함

'품위 유지, 이미지 유지'라는 명목으로 광고 모델의 사생활 관리에 대해 의무를 부과시키고 있다. 즉, 광고 계약이 사생활의 자유를 제약하고 있다. 하지만 민법 제103조에 따르면 계약의 자유가 보장된다고 하더라도, 이를 통해 개인의 자유를 심하게 제약해서는 안 된다.

따라서 구체적 행동을 적시하지 않은 채 단지 '사회적 물의'를 약정 해지 사유로 정한 경우에는, 그 요건을 까다롭게 심사해야 할 것이다. 왜냐하면 '사회적 물의'란 표현은 모호하고 그 사유도 너무 다양하기 때문에 이 약정에 그대로의 법적 효과를 부여한다면, 광고 모델의 사생활이나 표현의 자유가 지나치게 제한될 수 있기 때문이다. 가령, 연예인의 경우에는 자유로운 연애나 결혼, 이혼으로 인해서 사회적 물의가 일어날 수도 있고, 텔레비전에서 사소한 거짓말을 하거나, 특정 정당을 지지하는 발언을 해서 사회적 물의를 일으킬 수도 있다. 2021년에 인기 배우로 급부상했던 김선호의 사례를 살펴볼 수 있다. 당시 인기리에 방영된 드라마의 종영 후, 온라인 커뮤니티에 김선호의 사생활에 대한 폭로 글이 등장해 논란이 되었다. 보통 광고 모델이 이미지 훼손을 일으킬 경우, 광고주는 광고료의 2~3배에 해당하는 위약금을 요구하는 것으로 알려져 있다. 하지만 김선호에게 위약금을 청구한 회사는 없는 것으로 알려졌다. 왜냐하면 광고 계약 당시 관련 조항을 포함하지 않았기 때문이다.

광고 모델이 대중들로부터 '공격, 모욕, 멸시'를 받았다고 해서 광고 자체에는 직접적인 영향을 미쳤는지 평가하기 애매하다. 이러한 광고 계약에서 광고 모델의 사생활과 이미지 관리에 대한 모호한 부분이 기업에 리스크를 안길 수 있다.

(4) 복잡한 법적 절차와 책임 소재의 불확실성

유명 연예인 광고 모델이 논란을 일으켜 광고주에게 손해배상소송을 당한 사례를 쉽게 찾아볼 수 있다. 예를 들어, 2014년에 불법 도박 혐의로 기소된 코미디언 이수근은 광고 모델로 활동하던 자동차용품 전문업체 불스원으로부터 20억 원대 손해배상 소송을 당했다. 또한, 멤버 간 '왕따 논란'에 휘말린 그룹 티아라도 2012년 광고모델로 활동하던 샤트렌에 손해배상 소송을 당한 적이 있다. 이처럼 광고 모델과 광고주 간의 소송에서는 위약금 규모와 원인에 대한 분쟁, 법적 해석 등 다양한 복잡한 법적 절차가 수반된다. 이러한 상황에서 법정 절차에 따른 브랜드의 이미지 손상과 승소의 불확실성에 대한 리스크가 기업에 가해진다. 더불어, 유튜브 광고의 경우에는 기업과 유명 유튜버 간의 광고 계약은 종종 1대1 계약 형태로 이루어지지 않고 광고 대행사 등 다자 간 계약 형태로 진행되는 경우가 흔하다. 이로 따라 책임 소재가 불분명해지는 경우가 발생하며, 결과적으로 법적 복잡성과 승소의 불확실성은 더욱 증가한다.

이처럼 인기 유튜버를 활용한 마케팅은 언제나 양날의 검이다. 짧은 광고영상 하나만으로 브랜드 각인 효과를 확실하게 낼 수 있지만 앞서 제시한 연예인의 사례와 같이 유튜버 또한 언제나 불미스러운 사건·사고에 휘말릴 수 있는 리스크가 잠재되어 있다. 그러한 피해가 기업에게 심각한 리스크로 작용할 수 있기에 사전에 대비하고 관리할 수 있는 분석체계를 만들어 보고자 한다.

1.3 분석 과정

유튜버를 광고 모델로 선정 시 발생할 수 있는 기업 리스크를 분석하고 체계적으로 관리하기 위해서 다음과 같은 프로세스를 진행하였다. 우선 리스크 분석을 위해 기준점이 될 요소를 수집하였다. 해당 요소들은 유튜버의 평판에 영향을 미칠 수 있다고 고려되는 '영상에 관한 요소들', '구독자 및 시청자에 관한 요소들', '채널 전체의 요소'를 포함한다. 이때 영상에 관한 요소들 중 '댓글'은 시청자들의 유튜버에 대한 직접적인 평가를 볼 수 있는 것으로 판단하여 감성분석을 통해 긍/부정 정도를 확인하여 평가 요소로 사용하였다. 수집된 요소들을 인지도, 참여도, 성실도, 성장률이라는 네 가지 평가 항목으로 분류하고 항목별 점수를 부여하여 합산하여 총점수로 유튜버별 월 등급을 산출하였다. 끝으로 산출된 등급을 K-S 통계량과 PSI로서 평가모델의 변별력과 안전성을 확인하여 산출된 등급의 타당성을 확보하였다.




그림) 전체 프로세스 흐름도

본론

2 데이터 설명

2.1 분석 대상 설정

유튜브 내의 다양한 유튜버 및 콘텐츠는 마케팅 수단으로 활용되고 있으며, 그 효과 또한 기존의 광고보다 훨씬 효과적인 것으로 알려져 있다. '패션 및 뷰티 분야'는 유튜브 인기 카테고리 중 상위를 차지하고 있으며, 제품의 소개, 리뷰, 후기 등 다양한 콘텐츠를 제공하고 있다. 특히 패션 및 뷰티 계열의 기업들에서 유튜버를 활용한 마케팅을 활발하게 진행하고 있으며 매출 상승 효과 또한 크기에 본 프로젝트에서 연구 대상으로 선정하였다. 분석 기간은 2022년 8월부터 2023년 8월까지로 설정하였다. 분석 기간 내 영상 업로드를 한 유튜버 중, 채널의 구독자 규모를 고려하여 최종 247명의 패션 및 뷰티 유튜버를 선정하였다.

2.2 데이터 수집

본 프로젝트에서 유튜버의 데이터 수집은 유튜버의 Youtube 사이트를 크롤링하여 수집하였다. 웹 스크래핑 패키지인 BeautifulSoup와, 웹 UI 자동화 도구인 Selenium을 이용해 유튜버의 데이터 수집하였다. 크롤링으로 얻은 데이터 목록은 다음과 같다.

[영상별 업로드 날짜, 영상별 조회수, 영상별 좋아요 수, 영상별 댓글, 댓글별 좋아요 수, 댓글 작성자 id]
Youtube 사이트에서는 과거 시점의 구독자수를 구할 수 없기 때문에, 유튜버 데이터 제공 사이트인 블링에 나와 있는 과거 시점들의 [구독자 수]를 수동으로 수집하였다. [구독자 상승률]을 구하기 위해서 분석 기간인 2022년 8월부터 2023년 8월까지 구독자 수와 추가로 2022년 7월 구독자 수를 수집하였다.
그러나 수집 기간에 기존 영상이나 영상에 달린 댓글을 유튜버의 재량에 따라 삭제할 수 있다. 따라서 수집이 완료된 시점은 2023년 9월 30일로, 그 이후에 삭제된 영상이나 댓글에 대해서는 본 프로젝트에서는 고려하지 않는다.



그림) 크롤링 데이터 목록 예시 - 유튜버 '연두콩' 영상 업로드 날짜, 영상 별 조회수, 영상 별 좋아요 수




그림) 크롤링 데이터 목록 예시 - 유튜버 '연두콩' 영상, 영상 별 댓글, 댓글 별 좋아요 수, 댓글 작성자 id



그림) 크롤링 데이터 목록 예시 - 유튜버 '연두콩' 블링 구독자 수

2.3 데이터 전처리

유튜버의 재량으로 영상의 좋아요 수를 가리는 경우가 발생하여 결측치가 발생하였다. 해당 유튜버가 올린 모든 영상에 좋아요를 공개하지 않는다면, 분석 대상에 포함하지 않았다. 만약 하나라도 좋아요를 공개한 영상이 있다면, 결측치를 채우는 방식으로 처리하였다. 본 프로젝트에서는 도메인 지식을 통해 조회수와 좋아요 수가 밀접한 관계가 있다고 판단하였다. 좋아요 수가 공개된 영상들의 (좋아요 수 / 조회수)의 평균값을 계산하여, 좋아요 수가 비공개된 영상의 조회수에 곱해서 좋아요 수의 결측치를 채웠다.

3 데이터 분석

3.1 감성분석 모델

감성분석모델은 각 유튜버들의 영상 댓글의 긍부정을 판별하는 모델이다. 댓글의 긍부정 판별 후 영상별로 아래와 같은 방법으로 영상별 댓글 점수를 매긴다.

$$\frac{\sum \text{댓글 감성 점수} \times (1 + \text{댓글 좋아요 수})}{\text{총 댓글 수} + \text{총 좋아요 수}}$$

1. 사용 데이터

감성분석 모델의 학습을 위해서는 데이터에 긍부정에 대한 라벨이 필요하다. 하지만 본 프로젝트에서 수집한 유튜브 댓글 데이터에는 긍부정에 대한 라벨이 존재하지 않는다. 댓글 데이터의 수가 약 45만 개로 매우 큰 크기의 데이터이기 때문에 수동 라벨링을 하기에는 한계가 있다고 판단하였다. 따라서 감성분석 모델의 학습에 자주 사용되는 네이버 쇼핑 리뷰 데이터인 naver_shopping.txt를 사용하였다. 해당 데이터는 20만 건의 리뷰 데이터로 구성되어 있다. 별점 데이터가 포함되어 있어, 4~5점은 긍정으로, 1~2점은 부정으로 긍부정 라벨링을 진행했으며 긍부정 비율이 1:1로 구성되어 있다. 또한 3점 데이터는 전체 데이터 속에 포함되어 있지 않아 고려하지 않았다.

2. 데이터 전처리


본 프로젝트에서 분석에 사용하고자 하는 유튜브 댓글 데이터와 감성 분석 모델 학습을 위한 네이버 쇼핑 리뷰 데이터를 합쳐서 전처리를 진행하였다.

텍스트 데이터 중 한글 자음(ㅋㅋ, ㅎㅎ 등), 한글 모음(애애, 아아 등), 영어, 숫자, 특수기호, 이모티콘 등이 포함된 경우는 해당 요소들을 제거하였다. 만약 해당 요소들만 댓글이 구성된 경우에는 해당 댓글 데이터를 삭제하였다.

텍스트 데이터를 자연어 처리에 사용하기 위해서는 단어의 토큰화가 아닌 문장을 최소한의 의미를 가지는 요소로 토큰화하는 형태소(Morpheme) 분석 과정이 필요하다. 이에 본 프로젝트는 형태소 분석기 라이브러리인 KoNLPy(Korean NLP in Python) 중 트위터에서 제작한 한국어 형태소 분석기인 twitter-korean-text를 이어받은 Okt(Opensource korean text processor)를 사용하였다.

토큰화 이후 전체 텍스트 데이터의 단어 집합을 살펴보면, 단어가 약 26만 개가 존재한다. 등장 빈도가 threshold 값인 3회 미만인 단어들은 17만 개로 단어 집합에서 약 65%를 차지한다. 하지만, 실제로 전체 데이터에서 등장 빈도로 차지하는 비중은 매우 적은 수치인 약 1.9% 밖에 되지 않는다. 등장 빈도가 3회 미만인 단어들은 자연어 처리에서 중요하지 않을 것으로 판단하였고 이 단어들은 정수 인코딩 과정에서 배제했다. 제거 후 단어 집합의 크기는 87,370개이며 이를 단어 집합의 최대 크기로 설정한다.

패딩은 서로 다른 길이의 샘플들의 길이를 동일하게 맞춰주기 위한 작업이다. 이를 진행하기 위해 전체 데이터에서 최대 데이터 길이와 평균 데이터 길이, 전체 데이터의 길이 분포를 알아보았다. 리뷰의 최대 길이는 1217, 평균 길이는 약 18이며, 그래프로 봤을 때 전체적으로는 200 이하의 길이를 가지는 것으로 보인다. 만약 125로 패딩 할 경우, 전체 데이터의 99.05%가 125 이하의 길이를 가진다. 따라서 전체 데이터를 길이 125로 패딩을 진행하였다.



그래프) 전체 데이터의 길이 분포 그래프

3. 모델 구축 및 검증

LSTM을 이용해서 감성분석 모델을 구축하였다. 네이버 쇼핑 리뷰 데이터 20만 건 중 15만 건을 모델 학습용 데이터로 사용하였으며, 나머지 5만 건을 테스트용 데이터 세트로 사용하였다. 그리고 유튜브 댓글 데이터에서의 모델의 적합성을 확인하기 위해 전체 유튜브 댓글 데이터 중 긍부정과 유튜브를 고려하여 임의로 선택한 4,736개 데이터에 대해 긍부정 라벨링을 진행하였다.

하이퍼파라미터인 임베딩 벡터의 차원은 100, 은닉 상태의 크기는 128로 설정하였다. 모델은 LSTM 중 다 대 일 구조를 사용하였으며, 해당 모델은 마지막 시점에서 긍정, 부정을 분류하는 이진 분류 모델이다. 이진 분류 문제이기 때문에, 출력층에 활성화 함수로 시그모이드 함수를 사용하고, 손실 함수로 크로스 엔트로피 함수를 사용하였다. 하이퍼파라미터인 배치 크기는 64이며, 에포크는 15로 설정하여 학습을 진행하였다. validation_split=0.2를 사용하여 훈련 데이터의 20%를 검증 데이터로 분리해서 사용하고, 검증 데이터를 통해서 훈련이 적절히 되고 있는지 확인한다. 검증 데이터는 기계가 훈련 데이터에 과적합 되고 있지는 않은지 확인하기 위한 용도로 사용된다. 그리고 조기 종료(Early Stopping)에는 patience=4를 적용하여, 검증 데이터의 성능이 4번 개선이 안 된다면 학습을 종료한다.

최종적으로 구축한 모델을 네이버 쇼핑 리뷰 5만 건 테스트용 데이터와 유튜브 댓글 라벨링 데이터로 평가한 성능은 다음 표와 같다. 모델 학습에는 네이버 쇼핑 리뷰 데이터만을 사용했기 때문에 네이버 쇼핑 리뷰 테스트 데이터의 성능이 높은 사실은 예상한 결과이다.

유튜브 댓글 라벨링 데이터로 얻은 성능이 비교적 낮지만, 유튜브 댓글 전용 감성분석 모델이 아닌 점을 고려하면 준수한 성능을 보여준다고 판단하였다. 전체 유튜브 댓글 데이터에 라벨링을 진행하여 학습용 데이터 셋을 얻을 수 있다면, 유튜브 댓글 전용 감성 분석 모델을 구축하고 더 좋은 성능을 보여 줄 수 있을 것으로 예상된다.

사용 데이터	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1 점수 (F1-Score)
네이버 쇼핑 리뷰 테스트용 데이터	0.9146	0.9052	0.9257	0.9154
유튜브 댓글 라벨링 데이터	0.8239	0.9875	0.8278	0.9006

표) 감성 분석 모델의 데이터 별 성능

	comment	label	감성점수
	어깨라인이 예뻐서 어깨를 들어낸 룩은 다 예뻐요!!WrWn4, 5, 7번이 제 픽이...	1	0.981797
	전체적으로 앵글을 잡아주셨으면 더 좋았을 것 같아요 ππ 바지가 전체적인 핏이 잘 ...	0	0.380047
	언니! 언니는 잘 안 하긴 한다고 했지만 이 영상에 나오는 5호 팔레트로 효진님 겨...	1	0.944739
	헉쓰! 너무 예뻐요!!WrWn흑시 병원정보 메일로 받을 수 있을까요	1	0.953558
	휘귀? 먹을때 비위약하다한거 그거 뭐예용..징그럽게생겼어요	0	0.083958
	전 금발은 아니지만 대리만족하면서 봤어요 언니 ㅎㅎ 바비인형 같은 샌언니 ..	1	0.884551
	으 π	0	0.273340

그림) 댓글 감성 분석 예시
* label 값이 1일경우 해당 댓글은 긍정, 0일경우 부정을 의미

3.2 유튜버별 월 등급 산정

유튜버의 등급 산정은 기업 신용평가 방식을 차용하여 이루어진다. 기업 신용평가는 기업의 다양한 재무 및 비재무 요소를 분석하고 평가하여, 이를 기업의 부실 위험도와 신용 상태를 나타내는 '신용등급'으로 기호화한 것이다. 유튜버의 등급 산정 역시 이와 유사한 방식을 활용한다. 유튜버의 활동을 평가하기 위해 댓글, 조회수, 구독자 수 등의 다양한 요소를 분석하고 이를 범주화하여 점수화한다. 이후, 이러한 점수를 신용평가 방식과 유사한 10개의 등급(A+,A0,B+,B0,C+,C0,D+,D0,E,F)으로 나누어 등급을 부여한다. 이러한 방식을 통해 유튜버의 활동과 영향력을 정량적, 정성적으로 평가하고, 이 정보를 활용하여 기업의 판단에 활용된다.

1. 유튜버 등급의 의미

신용평점은 1~10등급으로 구분되며 1등급에 가까울수록 기업의 신용 수준이 높다고 할 수 있다. 유튜버의 등급 산정도 이와 유사하게 10개의 등급(A+,A0,B+,B0,C+,C0,D+,D0,E,F)으로 나누어 등급을 부여한다. 차이점이 있다면, 신용평가에서는 1등급에 가까울수록 신용 수준이 높다고 할 수 있지만, 유튜버의 등급은 A+등급에 가까울수록 잠재된 리스크가 높다고 할 수 있다.

2. 평가 항목

[1단계] 평가 항목 정의

평가 항목은 크게 인지도, 참여도, 성실도, 성장률로 나누며 각 항목에 따라 총 점수 100점을 기준으로 배점하였다. 최종 점수는 항목의 합으로 나오게 된다

- 인지도 : 시청자가 유튜버에 대해 느끼는 익숙함
- 참여도 : 영상에 대한 시청자의 참여 및 반응 정도
- 성실도 : 유튜버의 활동에 대한 진정성과 책임감
- 성장률 : 유튜버의 채널 성장 속도 정도

평가 요소 항목	세부 항목	설명
인지도 (30)	구독자수(15)	월 마지막 날 구독자수
	조회수(15)	월 영상의 평균 조회수
참여도 (30)	댓글 점수(10)	월 영상의 댓글 감성분석 점수 평균
	평균 영상 좋아요 수(10)	월 영상의 좋아요 수 평균
	충성도(10)	월 영상별 지속적으로 댓글을 다는 시청자의 비율
성실도 (30)	평균 영상간격(15)	월 영상간 날짜 간격의 평균
	영상 개수(15)	월 영상의 영상 개수 평균
성장률 (10)	구독자 수 성장률(10)	해당 월 구독자수/전 월 구독자 수

표) 평가 항목별 요소

[2단계] 필터링

월별로 수집된 요소에 의해 월 등급이 산출되기에 해당 월의 등급만으로는 유튜버의 전체적인 평판을 확인할 수 없다는 문제점이 있었다. 특히나 휴식기 등으로 영상을 업로드 하지 않아 영상에 관한 점수나 성실도에 대한 점수를 받지 못했을 경우 해당 월의 점수가 지나치게 감소하는 것을 현상이 존재하였다. 이러한 문제점을 해결하기 위하여 영상을 올리지 않아 점수가 낮게 산정되는 경우에는 영상에 관련된 점수에 한해 영상이 존재하는 전 월의 점수를 반영하기로 하였다. 이때 지속해서 영상을 올리지 않을 경우 실제로도 유튜버의 인지도나 여러 요소가 감소할 수 있음을 적용하여 1~2개월까지는 전월의 점수를 사용하고, 3개월부터는 3개월마다 전월의 점수를 사용하되 원래 부여되던 점수에 한 등급을 낮춘 점수로서 사용하여 더욱 정확한 등급을 산출하고자 하였다.


3. 유튜버 등급모형의 적정성

신용평가 성능지표란 각 기업이 향후 부실화 가능성을 얼마나 정확히 구분했는가(변별력)와 그 결과 얼마나 안정적으로 유지되는 가(안정성)을 통계적 기법을 통해 수치화한 것이다. 현재 사용된 유튜버 등급 모형의 변별력과 안정성을 확인하기 위해 신용평가 성능지표 중 K-S 통계량과 PSI를 사용하였다.

(1) K-S 통계량(Kolmogorov-Smirnov Statistics)

K-S 통계량은 우량집단과 불량집단의 누적분포의 차이를 나타내는 지표로, 신용평가모형의 변별력 평가 시 주요한 판별 통계량으로 사용된다. 이 지표는 신용등급에 따른 우량 집단과 불량 집단의 분포 차이를 비교하여, 누적 우량비율과 누적 불량비를 차이의 최대값으로 정의한다. 일반적으로 K-S 통계량 값이 30 이상이면 모형의 변별력이 충분하다고 판단한다.

인기 유튜버(B0 이상), 비인기 유튜버(C+ 이하)가 잘 구별 되는지 확인하기 위해 K-S통계량을 사용하였다. 등급별로 누적 인기 구성비와 누적 비인기 구성비를 산출한 후, 그 차이의 최대값으로 모형의 성능을 판단한다. 현재 사용된 평가모형의 경우, K-S통계량이 75.59289로 변별력이 높으며, 아래 그래프를 통해 인기 유튜버, 비인기 유튜버의 누적 분포가 확실히 차이 나는 것을 확인 할 수 있다.



그래프) 인기 유튜버, 비인기 유튜버의 누적 분포 비교

(2) PSI (Population Stability Index)

PSI는 개발 당시 모형과 비교 시점의 등급별 분포의 변화를 비교 분석하는 지표이다. 일반적으로 PSI가 0.1 미만인 경우 모집단 분포가 충분히 안정적이라고 볼 수 있으며, 0.25 이상인 경우 모집단 분포가 상당히 불안정하기 때문에 모형을 검토해야 할 필요가 있다. 현재 사용된 평가 모형의 경우, PSI가 0.1600053으로 안정적이라 판단된다.

등급	기준시점 (2022-08-31)	현재시점 (2023-08-31)	기준시점 구성비(%E)	현재 구성비(%O)	%O-%E	Ln(%O/%E)	PSI
A+	8	9	0.032389	0.036437	0.004049	0.117783	0.000477
A0	36	25	0.145749	0.101215	-0.04453	-0.36464	0.016239
B+	45	41	0.182186	0.165992	-0.01619	-0.09309	0.001508
B0	35	40	0.1417	0.161943	0.020243	0.133531	0.002703
C+	36	39	0.145749	0.157895	0.012146	0.080043	0.000972
C0	19	35	0.076923	0.1417	0.064777	0.610909	0.039573
D+	21	28	0.08502	0.11336	0.02834	0.287682	0.008153
D0	9	14	0.036437	0.05668	0.020243	0.441833	0.008944
E	20	10	0.080972	0.040486	-0.04049	-0.69315	0.028063
F	18	6	0.072874	0.024291	-0.04858	-1.09861	0.053374
합계	247	247	1	1			0.1600053

표) PSI 계산 결과

4. 모형의 적정성

평가 모형의 변별력을 검증하는 K-S 통계량은 30 이상일 경우 변별력이 확보되는 것으로 판단하며, 모집단의 안정성을 나타내는 PSI 는 0.25 미만인 경우 모집단의 분포가 안정적이라고 판단한다. 사용된 유튜브 등급 평가 모형은 적정기준을 충족하고 있다.

구분	성능지표	적정 기준치	해당 모형 통계량	적정성
변별력	K-S 통계량	30 이상	75.59289	충족
안정성	PSI	0.25 미만	0.1600053	충족

표) 평가 모형의 적절성 검증 결과

3.3 머신러닝 및 딥러닝 기법을 활용한 분석

1. 실험설계

(1) 머신러닝 기법을 활용한 실험 설계

본 실험에서는 2023년 8월 이전 시점의 데이터로 2023년 8월의 유튜버 평가 등급을 예측하고자 한다. 학습용 데이터는 2023년 7월 이전 시점의 데이터와 2023년 7월 유튜버 평가 등급을 사용하였다. 월 별 사용한 종속변수 들은 총 8개로, <표1>와 같다. 해당 변수들은 유튜버 평가 등급 산정에 사용된 점수와 동일하다. 분석 대상 유튜버 는 총 247명이다. 해당 실험은 두 가지 목적을 가지고 진행되었다. 첫 번째는 최신 N개월 데이터를 제공에 따른 성 능 차이를 확인하는 것이며, N값은 1, 3, 6으로 설정하였다. 두 번째는 유튜버 평가 등급을 크게 10등급, 5등급, 2 등급으로 나누어 각 등급의 개수에 따른 성능 차이를 확인하는 것이다. 각 개수의 등급으로 나누는 기준은 <표2>에 제시되어 있다. 총 9개의 경우로 나누어 실험을 진행하였으며, 각 실험의 내용은 <표3>에 제시되어 있다.

사용 변수
구독자 점수, 조회수 점수, 충성도 점수, 구독자 성장률 점수, 감성점수 점수, 평균 영상간격 점수, 평균 영상 좋아요 수 점수, 영상개수 점수

<표1>

등급 개수	등급 목록	비고
10등급	A+, A0, B+, B0, C+, C0, D+, D0, E, F	위에서 산정한 등급과 동일
5등급	A, B, C, D, F	A : A+, A0 B : B+, B0 C : C+, C0 D : D+, D0 F : E, F
2등급	인기 유튜버, 비인기 유튜버	A+ ~ B0 : 인기 유튜버 C+ ~ F : 비인기 유튜버

<표2>

실험	최신 N개월 데이터 제공	유튜버 평가 등급 개수
case 1	최신 1개월 데이터 제공 (2023년 7월)	10등급
case 2	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	10등급
case 3	최신 6개월 데이터 제공 (2023년 2월~2023년 7월)	10등급
case 4	최신 1개월 데이터 제공 (2023년 7월)	5등급
case 5	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	5등급
case 6	최신 6개월 데이터 제공 (2023년 2월~2023년 7월)	5등급
case 7	최신 1개월 데이터 제공 (2023년 7월)	2등급
case 8	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	2등급
case 9	최신 6개월 데이터 제공 (2023년 2월~2023년 7월)	2등급

<표3>

(2) 머신러닝 기법

머신러닝 모델은 로지스틱 회귀, 랜덤 포레스트, XGBoost, LightGBM를 사용하였으며, 각 모델에 대한 자세한 설명은 [부록 A]에 추가되어 있다. 모델들의 주요 파라미터 및 설정을 구현하기 위하여 Python 3.9.7 프로그램을 사용하였다. 머신러닝 모델 중 로지스틱 회귀 및 랜덤 포레스트는 Python의 Scikit-Learn 1.1.2 라이브러리를 사용하였으며, XGBoost 모델은 Python의 xgboost 1.7.5 라이브러리를, LightGBM 모델은 Python의 LightGBM 3.3.5 라이브러리를 사용하였다. 머신러닝 모델의 하이퍼 파라미터(Hyper Parameter) 중 random state는 재현할 수 있는 실험을 위해 42로 고정하였다. 그 외의 하이퍼 파라미터들은 Python의 Scikit-Learn, xgboost, LightGBM 라이브러리에서 제공하는 기본값들로 설정하였다.

(3) 딥러닝 기법을 활용한 실험 설계

본 실험에서는 머신러닝을 활용한 실험과 동일하게, 2023년 8월 이전 시점의 데이터로 2023년 8월의 유튜브 평가 등급을 예측하고자 한다. 역시 머신러닝을 활용한 실험과 동일하게, 학습용 데이터는 2023년 7월 이전 시점의 데이터와 2023년 7월 유튜브 평가 등급을 사용하였다. 해당 실험 또한 두 가지 목적을 가지고 진행되었다. 첫 번째는 최신 N개월 데이터를 제공에 따른 성능 차이를 확인하는 것이며, N값은 3과 수집된 전체 데이터 크기인 11로 설정하였다. 두 번째는 머신러닝을 활용한 실험과 동일하게 유튜브 평가 등급을 크게 10등급, 5등급, 2등급으로 나누어 각 등급의 개수에 따른 성능 차이를 확인하는 것이다. 총 6개의 경우로 나누어 실험을 진행하였으며, 각 실험의 내용은 <표4>에 제시되어 있다.

실험	최신 N개월 데이터 제공	유튜브 평가 등급 개수
case 1	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	10등급
case 2	최신 11개월 데이터 제공 (2022년 9월~2023년 7월)	10등급
case 3	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	5등급
case 4	최신 11개월 데이터 제공 (2022년 9월~2023년 7월)	5등급
case 5	최신 3개월 데이터 제공 (2023년 5월~2023년 7월)	2등급
case 6	최신 11개월 데이터 제공 (2022년 9월~2023년 7월)	2등급

<표4>

(4) 딥러닝 기법

딥러닝 기법은 시계열성을 잘 처리한다고 알려져 있는 LSTM 모형을 이용하였다. 모든 월 별 변수를 머신러닝 기법에서는 동일하게 보고 하나의 큰 입력 변수 벡터로 사용하였지만, LSTM 모형의 경우 시간의 흐름에 따라 동일한 변수들을 시간축으로 정렬하여 처리할 수 있다. 총 1개의 LSTM 은닉층에서 각 셀을 64개로 설정하였으며, epoch는 100, batch size는 16, 활성화 함수(Activation Function)는 하이퍼볼릭 탄젠트(tanh) 함수를 설정하였다. 그리고 모형의 과적합(Over-fitting) 문제를 피하고자 학습 이후에도 성능 개선이 연속 5번 이상 이루어지지 않으면 학습을 조기 중단하도록 하였다. 딥러닝 모형들의 손실함수(Loss Function)는 유튜브 평가 등급 개수가 2개, 즉 이진 분류의 경우에는 Binary Crossentropy를 사용하였고 출력층의 활성화 함수는 sigmoid 함수를 사용하였다. 그리고 유튜브 등급 개수가 5개, 10개의 경우, 손실함수는 categorical_crossentropy를 사용하였고 출력층의 활성화 함수는 softmax 함수를 사용하였다. 딥러닝 모형들의 옵티마이저(Optimizer)는 모두 Binary Crossentropy와 Adam으로 설정하였다.

2. 프로젝트 수행 결과

(1) 머신러닝 결과

머신러닝 모형들의 하이퍼 파라미터 설정을 토대로 정확도, 정밀도, 재현율, F1-점수의 관점에서 실험 case 별로 측정한 예측 성능은 <표5>에 제시되어 있다. 유튜버 평가 등급 개수가 10개인 경우(case 1, 2, 3)보다 유튜버 평가 등급 개수가 5개인 경우(case 4, 5, 6)가 높은 성능을 보여준다. 또한 유튜버 평가 등급 개수가 5개인 경우(case 4, 5, 6)보다 유튜버 평가 등급 개수가 2개인 경우(case 7, 8, 9)가 높은 성능을 보여준다. 즉, 유튜버 평가 등급 개수가 줄어들 수록 전반적인 성능이 상승함을 보여주고 있다. 하지만, 유튜버 평가 등급 개수를 고정시키고 최신 N개년 데이터 제공에 따른 성능 변화를 살펴보면 유의미한 변화가 발생하지는 않았다.

실험 case	모형(Model)	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1 점수 (F1-Score)
case 1	Logistic Regression	0.3239	0.3031	0.3239	0.3042
	Random Forest	0.3927	0.4011	0.3927	0.3780
	XGBoost	0.3522	0.3178	0.3522	0.3297
	LightGBM	0.3401	0.3346	0.3401	0.3301
case 2	Logistic Regression	0.2065	0.1943	0.2065	0.1978
	Random Forest	0.3725	0.3718	0.3725	0.3581
	XGBoost	0.3279	0.3143	0.3279	0.3116
	LightGBM	0.3360	0.3279	0.3360	0.3259
case 3	Logistic Regression	0.2146	0.2150	0.2146	0.2124
	Random Forest	0.4089	0.3798	0.4089	0.3818
	XGBoost	0.3684	0.3541	0.3684	0.3585
	LightGBM	0.3401	0.3264	0.3401	0.3309
case 4	Logistic Regression	0.5709	0.5995	0.5709	0.5547
	Random Forest	0.5951	0.6213	0.5951	0.5793
	XGBoost	0.5628	0.5299	0.5628	0.5435
	LightGBM	0.5506	0.5226	0.5506	0.5331
case 5	Logistic Regression	0.4534	0.4295	0.4534	0.4403
	Random Forest	0.5629	0.5646	0.5628	0.5558
	XGBoost	0.5830	0.5956	0.5830	0.5849
	LightGBM	0.5951	0.6021	0.5951	0.5960
case 6	Logistic Regression	0.4292	0.4344	0.4292	0.4285
	Random Forest	0.6154	0.6285	0.6154	0.6152
	XGBoost	0.5749	0.5807	0.5749	0.5745
	LightGBM	0.6032	0.6062	0.6032	0.6021

실험 case	모형(Model)	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1 점수 (F1-Score)
case 7	Logistic Regression	0.8462	0.8615	0.8485	0.8550
	Random Forest	0.8774	0.8667	0.8864	0.8764
	XGBoost	0.8462	0.8507	0.8636	0.8571
	LightGBM	0.8583	0.8760	0.8560	0.8659
case 8	Logistic Regression	0.8178	0.8372	0.8182	0.8276
	Random Forest	0.8623	0.8657	0.8788	0.8722
	XGBoost	0.8745	0.8855	0.8788	0.8821
	LightGBM	0.8745	0.8531	0.8924	0.8873
case 9	Logistic Regression	0.7894	0.8125	0.7879	0.8000
	Random Forest	0.8502	0.8571	0.8636	0.8604
	XGBoost	0.8664	0.8613	0.8939	0.8773
	LightGBM	0.8421	0.8496	0.8561	0.8528

<표5> 머신러닝 실험별 모형별 정확도, 정밀도, 재현율, F1-점수

(2) 딥러닝 결과

딥러닝 모형들의 하이퍼 파라미터 설정을 토대로 정확도, 정밀도, 재현율, F1-점수의 관점에서 실험 case 별로 측정한 예측 성능은 <표6>에 제시되어 있다. 유튜버 평가 등급 개수가 5개일 때는 최근 3개월 데이터로 예측한 경우(case 3)보다 최근 11개월 데이터로 예측한 경우(case 4)가 높은 성능을 보여준다. 하지만, 유튜버 평가 등급 개수가 2개일 때에는 최근 3개월 데이터로 예측한 경우(case 5)가 11개월 데이터로 예측한 경우(case 6)보다 높은 성능을 보여준다. 또한 유튜버 평가 등급 개수가 10개일 때(case 1, 2)는 데이터의 추가 여부에 따른 성능 차이가 발생하지는 않는다.

실험 case	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1 점수 (F1-Score)
case 1	0.4008	0.3582	0.4008	0.3768
case 2	0.3927	0.3724	0.3927	0.3772
case 3	0.5668	0.5638	0.5668	0.5641
case 4	0.5951	0.6185	0.5951	0.5826
case 5	0.8421	0.8496	0.8561	0.8528
case 6	0.8340	0.8824	0.7955	0.8367

<표6> 딥러닝 실험별 모형별 정확도, 정밀도, 재현율, F1-점수

3. 실험 결과 해석

결과에 대한 해석은 다음과 같다. 머신러닝과 딥러닝 실험에서 동일하게 유튜버 평가 등급 개수가 감소함에 따라 성능이 향상함을 보인다. 분류문제에서 라벨의 class 종류가 감소하면 전반적인 성능이 향상되는 것은 당연하다. 하지만, class 개수에 따른 성능을 비교해 보면 준수한 성능을 보여줌을 확인할 수 있다. 또한 10개의 등급을 예측하는 것에서 그치는 것이 아닌, 5개, 2개로 확장하여 희망하는 등급 분류에 맞춰 최적의 모형에 데이터를 투입한다면 기존에 등급이 있는 유튜버의 경우 기존 등급 대비 미래 시점의 등급 예측이 가능하다.

머신러닝과 딥러닝 실험에서 모델에 제공하는 데이터의 범위를 다르게 한 이유는 유튜버 평가 등급 예측이 시계열성을 띠는 가정이 있었기 때문이다. 하지만, 기대와는 다르게 모델에 제공하는 데이터의 범위에 따른 성능 차이는 유의미하게 나타나지 않았다. 또한 딥러닝 중 시계열 예측 모델인 LSTM이 머신러닝 모델보다 좋은 성능을 보여줄 것이라고 예상했다. 그러나, RandomForest나 XGBoost와 같은 머신러닝 모델의 성능이 더 높게 나타났다. 즉, 유튜버 평가 등급 예측에는 시계열적 접근의 유의미함이 없었다. 따라서, 시계열적 접근보다는 유의미한 변수 선택이나 파생 변수 생성 등 feature engineering을 통해 예측 성능을 향상하는 방향을 생각해 봐야 한다.

4. 등급평가와 예측의 활용


유튜버의 평판을 평가하고 예측하는 과정은 기업(브랜드)과 보험사에 유용한 정보를 제공할 수 있다. 대기업들은 유튜버와의 협업에 상당한 자금을 투자하는 경우가 많아서, 피해 규모가 상당히 클 수 있다. 따라서, 예측된 유튜버 등급을 통해 어떤 유튜버와 협업할 것인지 결정할 때, 그 유튜버의 영향력을 사전에 확인할 수 있다. 보험사 입장에서 평판 등급을 고려하여 적절한 보험료를 산정할 수 있게 된다. 한편, 중소기업은 예산이 한정되어 있기 때문에 유튜버와의 광고 협업이 중요한 마케팅 전략이다. 예측된 유튜버 등급을 활용하면 중소기업은 제한된 자원 내에서 효과적인 마케팅을 수행할 수 있으며, 잠재적인 리스크를 최소화할 수 있다. 보험회사 입장에서는 각 개별 계약이 상대적으로 소액일 수 있지만, 동시에 여러 사고가 발생할 경우 누적 위험이 상당할 수 있다. 따라서, 사전에 5등급 또는 10등급 체계로 예측하면 더 정확하게 리스크를 평가할 수 있다.

4 데이터 분석 결과

4.1 유튜버 등급 시계열적 분석

유튜버마다 산정한 점수를 사용하여 시계열 그래프를 그렸다. 다음과 같은 결과를 확인할 수 있었다. (1)갑작스러운 상승, (2)갑작스러운 하락, (3)지속적인 상승, (4)지속적인 하락, (5)등급이 여러 차례 변동, (6)평판이 높게 유지, (7)평판이 평균적으로 유지, (8)평판이 낮게 유지로 총 8가지 유형으로 나뉘어진다. 각 유형에 해당하는 유튜버들에게 기업이 광고를 제공하였을 경우 장점과 리스크를 분석하였다. 이 중 '(8)평판이 낮게 유지' 유형은 일반적으로 광고주 입장에서 유튜버에게 광고를 제공하지 않을 가능성이 크기에 해당 유형은 제외하고 설명하겠다.

(1) 갑작스러운 상승




장점

유튜버는 보다 양질의, 트렌드를 담은 콘텐츠를 제공하여 비교적 많은 조회수와 구독자를 단숨에 많이 끌어낼 수 있다.

리스크

등급 상승의 경우 유튜버 알고리즘을 통한 일시적 상승일 뿐일 가능성을 지닐 수 있으며 댓글 알바 혹은 매크로 등 부정적인 방법을 통한 상승일 경우 기업에서 바라던 실제적 상승이 아닐 수 있다.

(2) 갑작스러운 하강




장점

평판이 감소한 원인이 해당 '유튜버가 휴식을 취해 영상 업로드가 되지 않았음'이라면 다시 콘텐츠를 업로드하고 활동을 재개할 경우, 평판이 원래대로 올라갈 가능성이 있다. 따라서 미래 광고 효과를 기대할 수 있다.

리스크

해당 유튜버의 평판이 갑자기 떨어지는 원인은 그 유튜버와 관련된 부정적 사건이 발생하거나 하강 시점 이후로 영상을 업로드하는 빈도가 적어졌음에 있다. 이러한 상황에서는 해당 유튜버의 평판이 다시 회복되기 어려울 수 있으며, 만약 해당 시점의 평판 감소 원인을 충분히 파악하지 못한다면 광고주의 광고 효과가 줄어들 것으로 예상되어진다.

(3) 지속적인 상승




장점

유튜브 알고리즘의 영향을 꾸준히 받거나 지속적으로 새로운 구독자의 증가가 있는 경우, 이러한 유형은 광고 효과를 가장 크게 얻을 수 있다. 유튜버가 꾸준한 업로드와 콘텐츠 개선을 통해 알고리즘에 노출되고 새로운 구독자를 유치하면 그를 통해 광고 수익을 높일 수 있다.

리스크

시청자 층이 탄탄하고 유튜버를 향한 높은 신뢰감 때문에 해당 유튜버에게 광고 사실을 밝히지 않는 뒷광고 혹은 사생활 논란이 생길 경우에 본래의 기대 효과 크기만큼 브랜드 이미지에 부정적인 영향을 미칠 수 있다.

(4) 지속적인 하락




장점

광고비가 작고 기대하는 광고 효과가 작다면, 이에 따른 예상 리스크도 상대적으로 낮을 것이다.

리스크

영상 업로드를 자주 하지 않으면 노출 수가 줄어, 유튜버의 등급이 하락하게 된다. 이로 인해 해당 채널의 시청자와 구독자는 같은 주제로 콘텐츠를 제공하는 채널로 이동할 수 있다. 유튜버의 인기가 하락하면 광고의 관심도와 효과가 감소할 수 있으므로, 기업 입장에서는 광고 효과에 대한 리스크를 고려해야 한다.

(5) 등급이 여러 차례 변동




장점

뷰티 유튜버 카테고리 안에 포함되지만 먹방/여행/v-log 등 콘텐츠의 주제가 다양한 유튜버가 주로 분포하는 유형이다. 이런 점으로 영상 속 자연스러운 제품 노출을 통한 광고 효과를 기대해볼 수 있다.

리스크

다양한 콘텐츠를 업로드하기에 전문성이 상대적으로 떨어지며 기대했던 영상이 광고라는 것을 알게 된 시청자에게 부정적인 역효과를 일으킬 수 있다.

(6) 평판이 높게 유지




장점

성실도/참여도/인지도분야에서 높은 점수를 가지고 있기 때문에 광고효과가 좋다.

리스크

해당 유튜버의 영상 뿐만 아니라 같은 주제의 다른 영상들이 알고리즘을 통해 계속 탐색 피드에 올라온다면 시장자의 피로를 느끼게 된다. 이로 인해 채널에 들어가지 않아 역으로 광고효과가 줄어드는 리스크가 존재할 수 있다. 또한 시청자층이 탄탄하고 높은 신뢰감 때문에 해당 유튜버에게 뒷광고 혹은 사생활 논란이 생길 경우에 브랜드 이미지를 더욱 부정적인 영향을 미칠 수 있다.

(7) 평판이 평균적으로 유지



장점

뷰티 카테고리도 헤어/네일/옷분야로 세분화할 수 있다. 등급을 중간 정도로 유지하는 유튜버들은 한 분야에 특화된 콘텐츠로 전문성이 높은 경우가 많다. 그에 따라 코어 시청자층이 많아 참여도(충성도)가 높다. 따라서 유튜버에 대한 구독자들 및 시청자의 신뢰도가 높고 전문적이므로 잘못된 정보를 구독자에게 전달할 가능성이 적어 브랜드의 이미지 실추에 대한 리스크가 적다.

리스크

한 분야에 전문적으로 활동하는 유튜버가 주로 이 유형에 포함되므로 해당 분야에 관심이 없는 시청자들을 대상으로 한 광고의 효과는 낮을 수 있다는 리스크가 존재한다.

결론

5.1 유튜버 평판 리스크 보험

최종적으로 유튜버의 평판을 등급화하여 추이를 분석하고 각 경우에 일어날 수 있는 리스크를 파악하였다. 이러한 리스크를 평판리스크라 정의하였다. 해당 리스크를 기업의 입장에서 바라보고 리스크를 보상받을 수 있는 보험을 제시하고자 한다.

(1) 보상하는 손해(Risk)

- 평판 리스크는 높은 등급의 유튜버일수록 크다고 보인다. 높은 등급을 유지하고 있는 유튜버들은 대중들에게 많은 신뢰를 받는다. 이런 기대감으로 광고 효과를 바라는 기업(브랜드)들은 높은 가격을 지불하고 광고하게 된다. 예상치 못한 사생활 논란으로 유튜버의 등급이 하락되어 피해를 입은 경우 이를 보상해 준다.
- 보상의 기준은 계약 시점 직전까지 최소 3개월 이상 B등급 이상의 인기를 유지하고 있는 유튜버가 C+이하 등급으로 하락할 경우, 기업에게 광고 비용과 브랜드 이미지 회복 비용을 지불한다.
- 기본적으로 계약서에 포함되지 않는 조항에 대해서 보상하나, 그 피해 정도가 위약금을 초과할 경우에 추가 보상을 받을 수 있다. 다만 추정되는 피해 정도가 계약상 위약금보다 낮은 경우에는 보상하지 않는다.

(2) 가입대상

유튜버를 대상으로 한 광고 계약 맺은 모든 기업 (단, 3번 이상의 과거에 논란이 발생한 유튜버와 광고 계약을 맺은 기업은 제외)

(3) 보상 요건


- 기업의 피해가 우발적인 논란 발생으로 인한 유튜버의 이미지 실추였을 경우
- 실시청자나 실구독자의 비율이 일정 이상일 경우
- 실제적 손해가 발생하고 그 파악이 가능한 경우

(4) 보험 기간


- 광고 계약 당 보험 : 실제 광고 계약 기간을 기준으로 보험기간을 정하는 보험
- 기간보험 : 보험기간을 1년 또는 6개월로 정하고 기간 내에 발생한 리스크를 보상해주는 보험

국내와 달리 WTW, Hiscox 등 해외 보험 회사에서는 인플루언서를 대상으로 하는 보험 상품을 제공하고 있다. 그러나, 기업의 손해를 보상해주는 보험 상품은 아직 국내외에 존재하지 않다. 광고 모델의 예기치 못한 사소한 행동으로 인한 손해는 기업이 고스란히 감당해야할 몫이다. 따라서 기업의 리스크를 보상할 수 있는 보험 상품을 개발함으로써 유튜버와 기업 간의 관계를 안정적으로 유지할 수 있게 된다.

5.2 페르소나 설정



M 기업에서는 이번 신제품 홍보를 위하여
최근 큰 화제를 모은 유튜버 A씨를 홍보 모델로 계획하였다.
기업에서는 평판 시스템을 통해 A씨의 과거 BO였지만
해당 월의 등급이 A+까지 상승한 것을 확인하였고 해당 보험을 가입 후 계약을 진행하였다.



5.3 한계 및 연구 방향

- 댓글 알바 등 부정적으로 기록된 사용자에게 대한 처리를 할 수 없었다.
- 조회수, 좋아요 수와 같은 데이터는 정확한 과거 시점의 값을 얻을 수 없어, 누적된 현재 시점의 값을 사용하였다.
- 유튜버에 한정하여 프로젝트를 진행하였으나 인플루언서로 확장하여 보다 더 넓은 범위를 포괄하는 프로젝트 연구가 가능하다.
- 유튜브 댓글 감성분석의 경우, 유튜브 댓글에 긍부정 라벨을 수동으로 달기에는 한계가 있어, 쇼핑 리뷰 데이터를 기반으로 한 감성 분석 모델을 활용하였다. 따라서, 그에 따른 감성 점수에 대한 신뢰성이 떨어진다. 유튜브 댓글에 대해 라벨링 된 데이터를 확보할 수 있다면 유튜브 댓글 전용의 감성분석 모델을 구축 가능하다. 이에 따라 감성점수가 더욱 신뢰성 있는 평가 지표로 쓰일 수 있을 거라 기대한다.

부록 및 참고문헌

부록 A. 머신러닝 및 딥러닝 방법론

A.1 전통적 통계 기법

(1) Logistic Regression

전통적인 통계기법으로 로지스틱 회귀 방법론을 사용했다. 로지스틱 회귀는 분류 문제에 주로 사용되는 간단하면서도 강력한 모델이다. 이 모델은 종속 변수와 독립 변수 간의 관계를 설명하는데 사용된다. 로지스틱 회귀의 핵심 목적은 주어진 독립 변수들을 기반으로 입력 데이터가 어떤 클래스에 속할 확률을 예측하는 것이다. 로지스틱 함수는 이 확률을 계산하기 위해 사용된다. 일반적으로, 0.5를 기준으로 확률이 0.5보다 크면 해당 데이터를 양성 클래스로 분류하고, 작으면 음성 클래스로 분류한다.

A.2 머신러닝 앙상블 모형

(2) Random Forest

Random Forest는 의사 결정 트리를 기반으로 한 앙상블 학습 방법으로, 다수의 결정 트리를 구성하고 그들의 예측 결과를 종합하여 최종 예측을 수행한다. 이러한 모델은 데이터의 비선형성과 상호작용을 고려하여 예측력을 강화하는 특징을 가지고 있다.

(3) XGBoost

XGBoost는 eXtreme Gradient Boosting의 약자로, Gradient Boosting 알고리즘을 개선하여 정확도와 성능을 높인 알고리즘이다. XGBoost는 트리 기반의 앙상블 모델로, 약한 학습기(weak learner)인 결정 트리를 여러 개 조합하여 강력한 예측 모델을 구성한다. 이를 통해 비선형 관계를 모델링하고, 변수의 중요도를 추정할 수 있다.

(3) LightGBM

LightGBM은 Gradient Boosting 알고리즘을 기반으로 한 빠른 속도와 고성능을 제공하는 알고리즘이다. 이 모델은 트리 기반의 앙상블 학습 방법으로, XGBoost와 마찬가지로 약한 학습기인 결정 트리를 조합하여 강력한 예측 모델을 형성한다. LightGBM은 대용량 데이터셋에 대한 처리 성능이 우수하며, 범주형 변수의 자동 변환과 결측치 처리 기능을 제공하여 모델 구축을 용이하게 한다.

A.3 딥러닝 모형

(1)LSTM

본 연구에서는 기존의 통계적 모델 외에도 딥러닝 모델 중 하나인 LSTM을 도입하여 재무적 부실 예측을 수행했다. LSTM은 순환 신경망(Recurrent Neural Network)의 한 종류로, 시계열 데이터나 순차적인 데이터에서 장기적인 의존 관계를 학습하는 데 특화된 모델이다. LSTM은 장기 의존성 문제를 해결하기 위해 게이트 메커니즘을 사용하여 정보를 보존하고, 불필요한 정보를 삭제함으로써 순차적인 데이터의 특징을 잘 파악할 수 있다.

참고 문헌

(1) 김윤, 김고운. (2020). 글로벌 패션 유튜버의 콘텐츠 유형과 특성에 관한 사례연구. 복식문화연구, 28(3), 389-407.

(2) 박주하, 전재훈. (2020). 패션 유튜브에 표현된 외모지상주의에 대한 연구 - 영상 및 댓글 분석을 중심으로 -. 한국패션디자인학회지, 20(1), 35-53.

(3) 김혜성, 김세형, 강주영. (2022). 인플루언서 마케팅 효과 증진을 위한 유사충성도 개념 기반 유튜브 팬덤의 충성도 분석: 패션 유튜버를 중심으로. 서비스경영학회지, 23(5), 106-133.

(4) 블링 vling, <https://vling.net/> [2023년 10월 11일].

(5) 소셜러스socialerus, <https://socialerus.com/> [2023년 10월 11일].

(6) 소셜러스socialerus, <https://socialerus.com/premium/reportcenter> [2022 한국 유튜브 분석 보고서].

(7) 陳祖容. "SNS를 통한 마케팅과 인플루언서의 특성이 브랜드 태도, 인플루언서에 대한 신뢰 및 브랜드 충성도에 미치는 영향." 국내박사학위논문 가천대학교 일반대학원, 2022. 경기도

(8) 권승면. "머신러닝을 활용한 물류기업 신용평가 예측모형 연구." 국내박사학위논문 중앙대학교 대학원, 2023. 서울

(9) 볼프강 M. 슈미트, 인플루언서 :디지털 시대의 인간 광고판, 강희진, 미래의창, 2022,311

사용 데이터와 코드

https://github.com/scnelMG/Samsungfire_Risk_Management